UNIVERSIDAD NACIONAL DE INGENIERIA

REDES NEURONALES · EXAMEN PARCIAL · PREGUNTA 2

Mapeo de inundaciones con Sentinel-1 y una U-Net propia

Etiquetas doradas vs. débiles en Sen1Floods11 y generalización a Lima 2017 (Copernicus EMSN038)

Gabriel Ángel Nizama Duque

César Luis Jiménez Miranda

Juan José Pino Reyes

Martín Alexis Valdiviezo Palma

OCTUBRE DE 2026 / GITHUB.COM/GABO2607/SEN1FLOODS11-UNET

MAESTRÍA EN INTELIGENCIA ARTIFICIAL / ESCUELA DE POSGRADO

El problema

Durante una inundación, las nubes ciegan a los satélites ópticos. El radar de Sentinel-1 las atraviesa, de día y de noche.

11
eventos de inundación en 4 continentes (Sen1Floods11)

446
chips etiquetados a mano por expertos (512×512 px, 10 m)

4,384
chips con etiqueta débil: umbral de Otsu, sin humano

VV + VH
las dos polarizaciones del radar como entrada

La tarea

Segmentar píxel a píxel el agua con una **U-Net escrita desde cero**, decidir con experimentos cómo usar las etiquetas débiles y medir si el modelo funciona en una región que nunca vio.

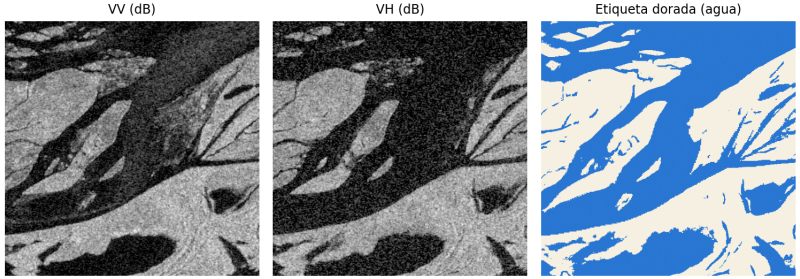
El precedente peruano

Marzo de 2017, El Niño costero: desbordes del Rímac y del Chillón en Huachipa, Carapongo, Comas y Puente Piedra. Copernicus EMS activó el mapeo **EMSN038**.

Datos y particiones

CONJUNTO	CHIPS	USO
Dorados · entrenamiento	252	entrenar
Dorados · validación	89	elegir época y variante
Dorados · test	90	en distribución
Bolivia (evento retenido)	15	fuera de distribución
Débiles (Otsu sobre S1)	1,000	ablación de datos
Lima 2017 (construida)	**19**	**generalización al Perú**

Los 1,000 débiles se eligen al azar **sin Bolivia y sin ninguna ubicación de validación o test**: así no se filtra información a la evaluación. Los píxeles sin datos se ignoran en la pérdida y en las métricas.



Chip de India (test). El agua calma refleja la señal lejos del sensor y se ve **oscura**: esa es la firma que aprende la red.

Nuestra región de prueba: Lima, marzo de 2017

Imagen: Sentinel-1B, 17-mar-2017

Escena IW dual-pol (VV+VH), una de las que usó el propio Copernicus. La pasamos a σ^0 en dB, 10 m y EPSG:4326, como Sen1Floods11.

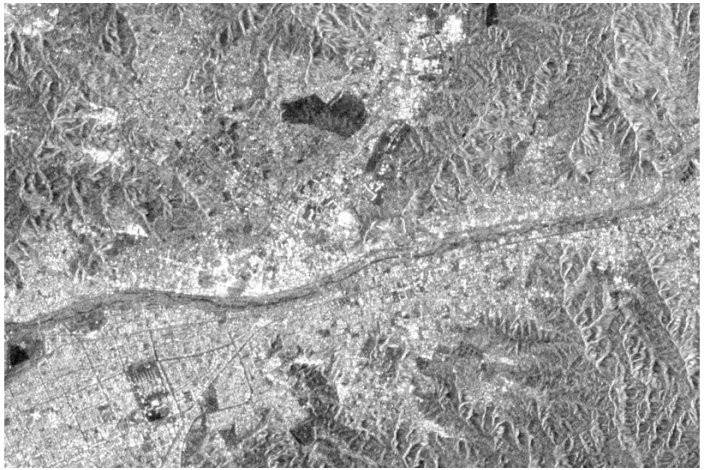
Etiqueta: Copernicus EMSN038

Capa *Potential Maximum Flood Extent*, delineada sobre WorldView-2 del 18 y 21 de marzo, rasterizada sobre la misma grilla.

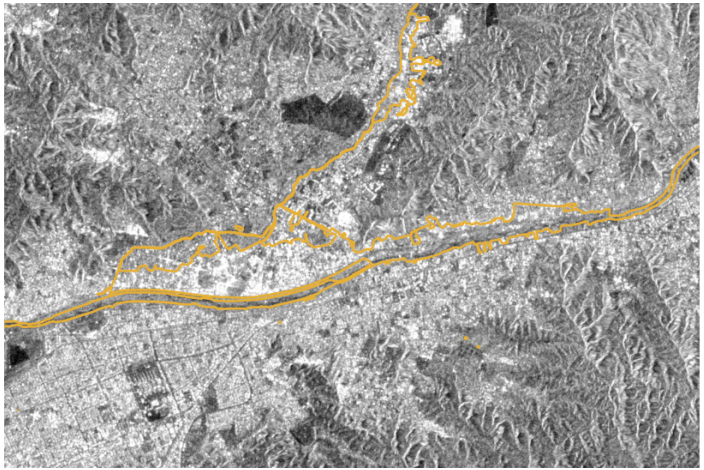
Resultado

19 chips de 512×512 con ~1.9 km² de agua de referencia. Es supervisión débil: óptica, de otra fecha y otro criterio.

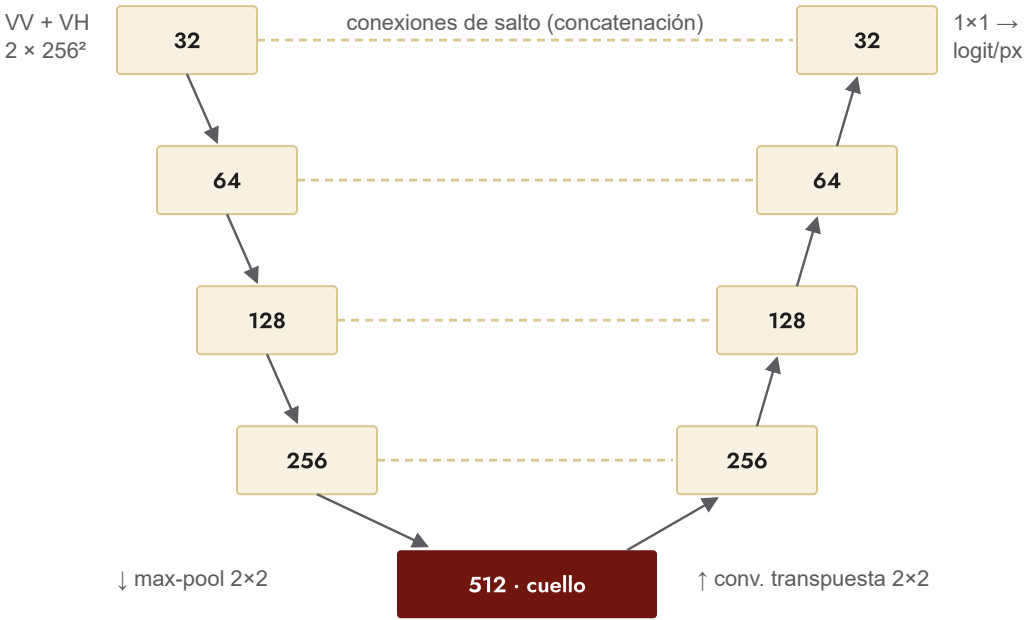
Sentinel-1 VV · 17-mar-2017 (Huachipa, río Rímac)



+ inundación EMSN038 (WorldView-2, 18–21 mar)



U-Net escrita desde cero en PyTorch



7.8 M

parámetros, sin librerías de segmentación

Cada bloque

(Conv 3×3 → BatchNorm → ReLU) × 2. Profundidad 4 y canales base 32, configurables.

Salida

Un logit por píxel; sigmoide > 0.5 = agua.

Entrenamiento y métricas

Optimización

- AdamW, lr 10^{-3}, decaimiento coseno
- Lotes de 8 recortes de 256×256 con volteos
- 40 épocas × 31 pasos; precisión mixta (GPU T4, ~6 min)

Tres pérdidas

- **BCE**: error por píxel
- **Dice**: solapamiento; robusta al desbalance agua/tierra
- **BCE+Dice**: promedio de ambas

Métricas (clase agua)

- IoU global y **IoU promedio por chip** (la de los autores)
- F1, precisión, recall
- Matriz de confusión

Regla de oro: decidir solo con validación

La mejor época, la mejor variante y el modelo final se eligen **solo por IoU de validación**. Test, Bolivia y Lima nunca intervienen en una decisión: se miran una sola vez, al final.

Comparación justa

Todas las variantes hacen el **mismo número de pasos** de optimización. Comparamos estrategias de datos, no cuánto cómputo recibió cada una.

Diseño de la ablación: 5 experimentos, 2 rondas

	DATOS DE ENTRENAMIENTO	PÉRDIDA
● **gold**	Solo los 252 dorados	BCE+Dice
● **mixed**	Dorados + 1,000 débiles mezclados	BCE+Dice
● **pre → ft**	20 ép. con débiles, 20 ép. afinando con dorados	BCE+Dice
bce	Ganador de (a)	Solo BCE
dice	Ganador de (a)	Solo Dice

(a) ¿Cómo combinar etiquetas doradas y débiles? · (b) ¿Qué función de pérdida?

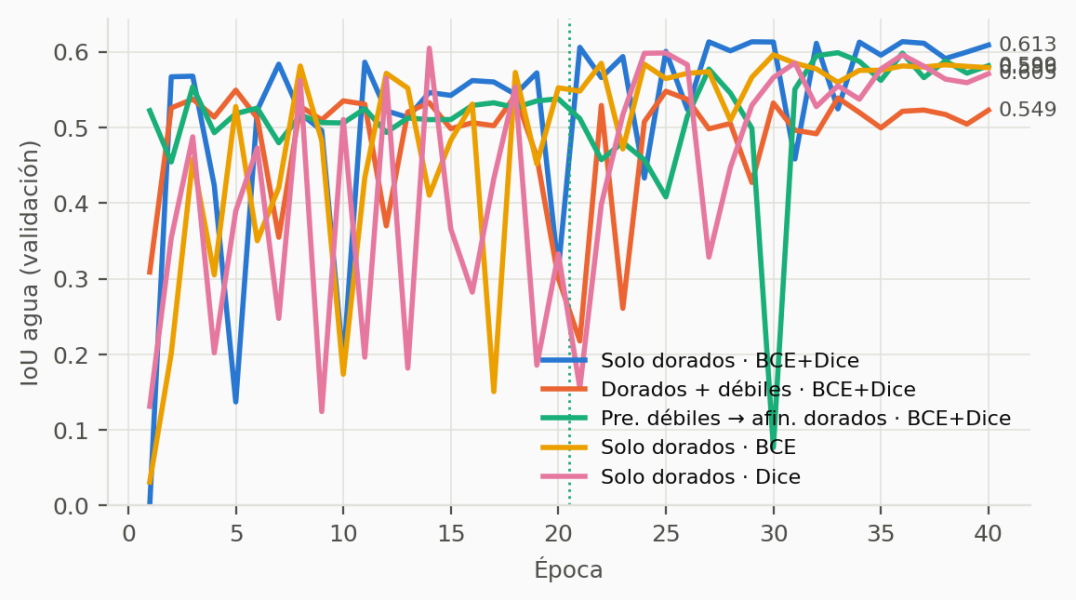
Ronda 1 · semilla 0

Un entrenamiento por experimento. Gana **gold**, pero el IoU de validación salta entre épocas (de 0.61 a 0.46).

Ronda 2 · semillas 1 y 2

Repetimos los 5 para saber si las diferencias son reales o azar. Reportamos **media ± desviación sobre 1 entrenamientos**.

Aprendizaje: media de las semillas por experimento



(a) Datos

Mezclar débiles queda por debajo durante todo el entrenamiento: la pérdida baja más, pero aprende los errores del umbral de Otsu.

(b) Pérdida

Las tres convergen a niveles parecidos; la banda muestra cuánto varía cada una entre semillas.

Resultados de la ablación

EXPERIMENTO	IOU VAL	IOU TEST	IOU/CHIP TEST	IOU BOLIVIA	IOU LIMA
Solo dorados · BCE+Dice	**0.613**	**0.647**	**0.399**	**0.677**	**0.012**
Dorados + débiles · BCE+Dice	0.549	0.596	0.324	0.670	0.003
Pre. débiles → afin. dorados	0.599	0.647	0.372	0.590	0.003
Solo dorados · BCE	0.596	0.647	0.343	0.574	0.000
Solo dorados · Dice	0.605	0.636	0.358	0.681	0.001

Media ± desviación estándar sobre 1 semillas. En negrita, el mejor por IoU de validación.

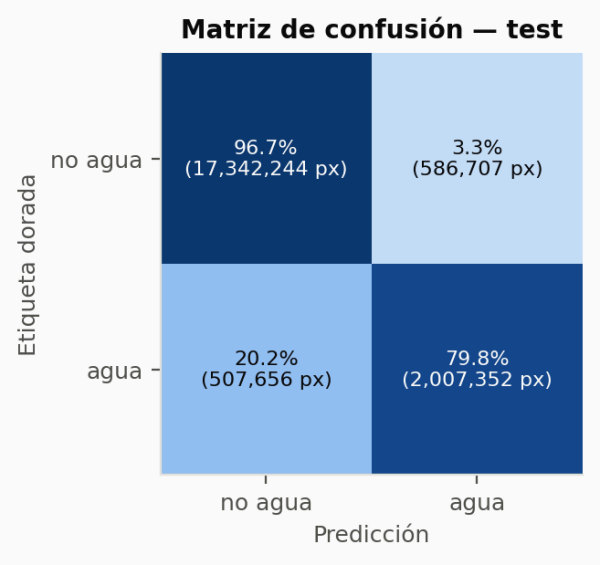
Las etiquetas débiles no ayudaron

A igual cómputo, mezclarlas es lo peor: 4 de cada 5 chips que ve la red son ruidosos. Preentrenar y afinar recupera casi todo, pero no supera a los dorados solos.

IoU global vs. por chip

El IoU por chip es mucho menor: en chips con poca agua, unos pocos píxeles errados hunden el cociente, y cada chip pesa igual.

Mejor modelo en el test dorado



0.647
IoU agua (test)

0.786
F1

0.774
precisión

0.798
recall

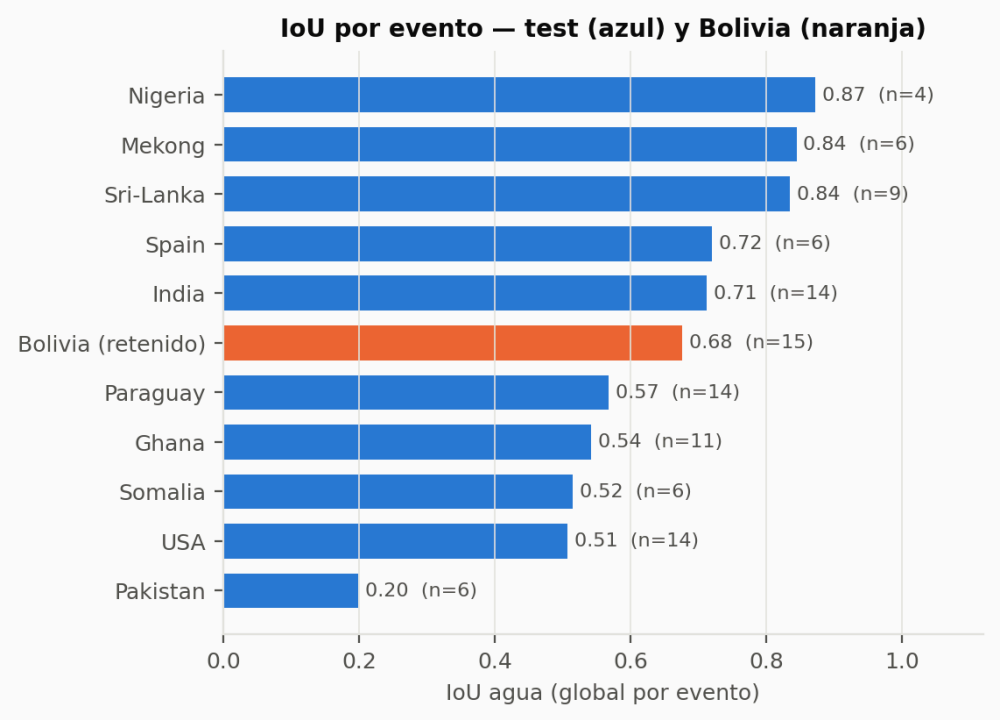
Qué dice la matriz

El error dominante es la **omisión**: se pierde el **20.2 %** del agua, frente a solo el **3.3 %** de la tierra marcada como agua. Como hay unas 7 veces más tierra que agua, esos pocos falsos positivos igual pesan en la precisión.

Contexto

Está en el rango que reportan los autores de Sen1Floods11 para redes entrenadas solo con S1 (IoU ≈ 0.6–0.7).

No todas las inundaciones son iguales



Fáciles

Sri Lanka, Nigeria, Mekong: grandes láminas de agua abierta y calma, oscuras en el radar.

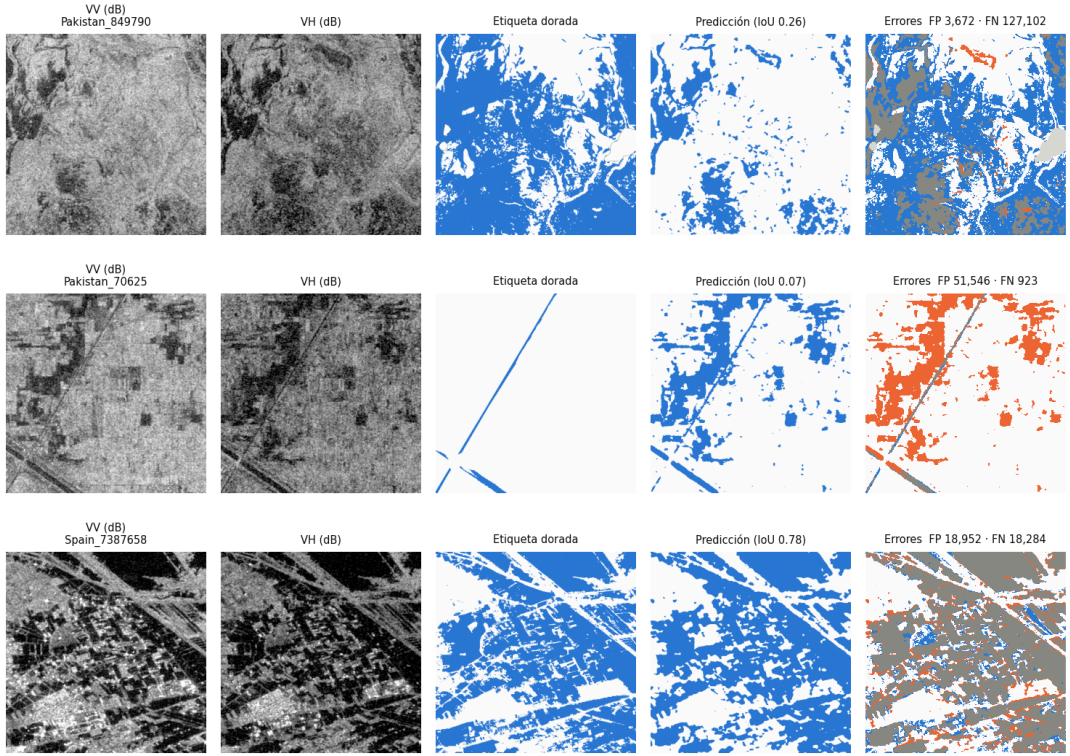
Difíciles

Pakistán y Somalia: agua somera entre cultivos y vegetación que asoma, que no se ve oscura.

Lima, al fondo

Muy por debajo de cualquier evento de entrenamiento. Lo explicamos en la sección 4.

Tres errores característicos del radar



1 · Vegetación inundada

Los tallos sobre el agua rebotan la señal y el píxel no se ve oscuro: **omisión** (azul).

2 · Suelo húmedo y liso

Campos anegados o recién arados son tan oscuros como el agua: **comisión** (naranja).

3 · Doble rebote urbano

Fachada + agua devuelven un eco muy brillante: el agua entre edificios desaparece.

acierto FP FN

¿Generaliza a regiones nunca vistas?

0.647
IoU en test (eventos vistos)

0.677
IoU en Bolivia (evento retenido)

0.012
IoU en Lima 2017 (EMSN038)

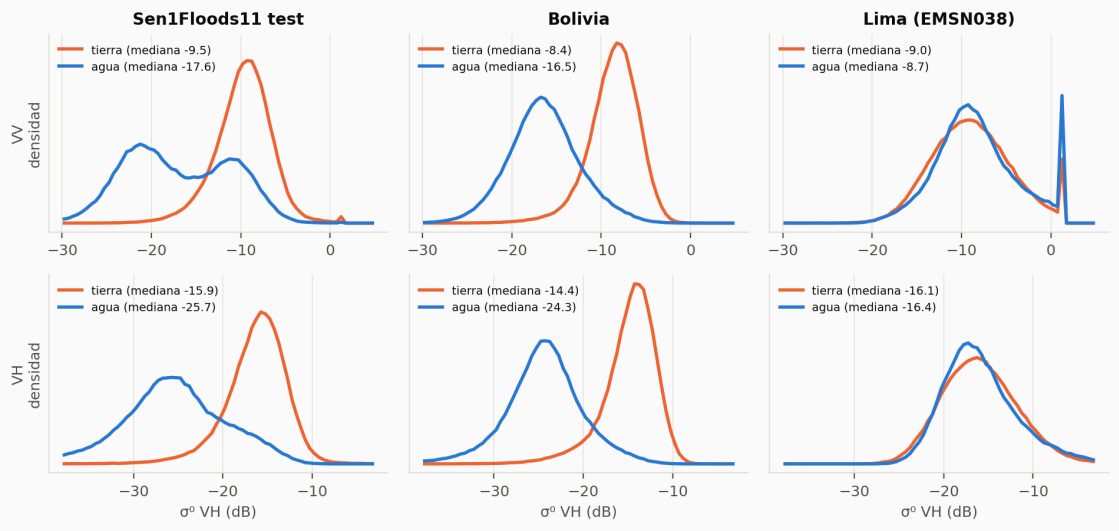
Bolivia: sin brecha

Inundación fluvial en llanura, con agua abierta y etiquetas del mismo protocolo. **Cambiar de región no basta** para degradar al modelo cuando el fenómeno físico es el mismo.

Lima: colapso

Todos los modelos caen por debajo de 0.02 de IoU, con precisión y recall menores al 5 %. ¿Falla el modelo… o falla el dato?

En Lima, el “agua” se ve igual que la tierra



VV, MEDIANA	AGUA	TIERRA
Test	−17.6	−9.5 dB
Bolivia	−16.5	−8.4 dB
Lima	**−8.7**	**−9.0 dB**

Ningún modelo solo-SAR podría separarlos

No es falta de capacidad de la red: la referencia no tiene la firma del agua abierta en esta escena.

Agua turbulenta y lodo

Huaicos con sedimento: superficie rugosa, no espejo.

Doble rebote urbano

Más ecos saturados (+1 dB) en el “agua” que en la tierra.

Etiqueta de otra fecha

Extensión *máxima*, delineada el 21 con el agua en retroceso.

Limitaciones y mejoras

Limitaciones

- Solo 1,000 de los 4,384 chips débiles; no probamos los de Sentinel-2.
- Tres semillas por experimento y 40 épocas cortas.
- La referencia de Lima es óptica, de otra fecha y otro criterio: la brecha mezcla error del modelo y de la etiqueta.
- Conversión aproximada de γ^0 a σ^0 para la escena de Lima.

Mejoras

- Afinar con unos pocos chips etiquetados de eventos peruanos.
- Agregar un modelo de elevación (HAND) para descartar sombra de radar y zonas altas.
- Fusión con Sentinel-2 cuando no haya nubes (bono).
- Ponderar las etiquetas débiles por confianza en lugar de mezclarlas.

Conclusiones

01 Una U-Net propia de 7.8 M de parámetros, solo con radar, logra un IoU de **0.647** en el test dorado.

02 Con igual cómputo, las etiquetas débiles no ayudaron: mezclarlas empeora y preentrenar + afinar apenas empata.

03 Repetir con 3 semillas mostró qué diferencias son reales y cuáles son ruido de entrenamiento.

04 Generaliza a otra inundación de llanura (Bolivia), pero no a Lima 2017: allí el agua no se ve oscura en el radar.

05 Para el Perú hacen falta ejemplos locales y datos auxiliares antes de confiar en un modelo entrenado en otras regiones.

Gracias.